ЛАБОРАТОРНА РОБОТА № 3

ДОСЛІДЖЕННЯ МЕТОДІВ РЕГРЕСІЇ

Мета роботи: використовуючи спеціалізовані бібліотеки та мову програмування Python дослідити методи регресії даних у машинному навчанні.

Завдання 2.1

```
import pickle
import numpy as np
from sklearn import linear_model
import sklearn.metrics as sm
import matplotlib.pyplot as plt

# Вхідний файл, який містить дані
input_file = 'data_singlevar_regr.txt'

# Завантаження даних
data = np.loadtxt(input_file, delimiter=',')
X, y = data[:, :-1], data[:, -1]

# Розбивка даних на навчальний та тестовий набори
num_training = int(0.8 * len(X))
num_test = len(X) - num_training

# Тренувальні дані
X_train, y_train = X[:num_training], y[:num_training]
# Тестові дані
X_test, y_test = X[num_training:], y[num_training:]

# Створення об'єкта лінійного регресора
regressor = linear_model.LinearRegression()
regressor.fit(X_train, y_train)

# Прогнозування результату
y_test_pred = regressor.predict(X_test)

# Побудова графіка
plt.scatter(X_test, y_test, color='green')
plt.plot(X_test, y_test_pred, color='black', linewidth=4)
plt.xticks(())
plt.yticks(())
plt.show()
print("Продуктивність лінійної регресії:")
print("Середня абсолютна похибка =", round(sm.mean_absolute_error(y_test,
y_test_pred), 2))
print("Середня квадратична помилка =", round(sm.mean_squared_error(y_test,
y_test_pred), 2))
print("Середня абсолютна помилка =", round(sm.median_absolute_error(y_test,
y_test_pred), 2))
print("Пояснена оцінка дисперсії =", round(sm.explained_variance_score(y_test,
```

```
y_test_pred), 2))
print("R2 оцінка =", round(sm.r2_score(y_test, y_test_pred), 2))
output_model_file = 'model.pkl'

# Збереження моделі
with open(output_model_file, 'wb') as f:
    pickle.dump(regressor, f)

# Завантаження моделі
y_test_pred_new = regressor.predict(X_test)
print("\nНова середня абсолютна помилка =", round(sm.mean_absolute_error(y_test,
y_test_pred_new), 2))
```

```
Продуктивність лінійної регресії:
Середня абсолютна похибка = 0.59
Середня квадратична помилка = 0.49
Середня абсолютна помилка = 0.51
Пояснена оцінка дисперсії = 0.86
R2 оцінка = 0.86

Нова середня абсолютна помилка = 0.59
```

Рис.1 Результат виконання

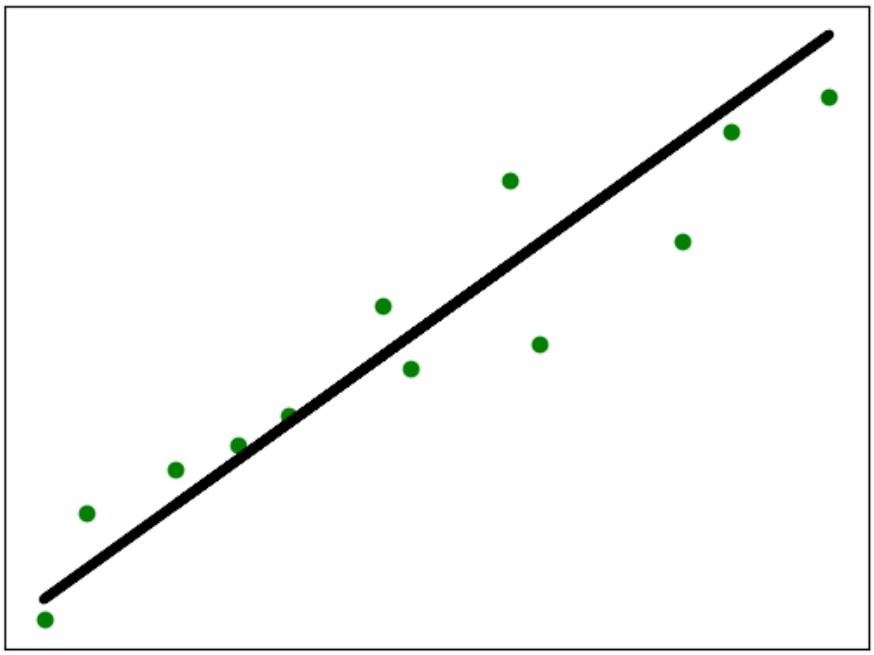

Рис. 2 Графік функції

Висновок: ми можемо використовувати цей спосіб для статистичного аналізу, який намагається показати зв'язок між двома змінними. Лінійна регресія може створити модель прогнозування за ніби-то випадковими даними, показуючи тенденцію в даних. Наприклад для цін або акцій.

Завдання 2.2

```
import pickle
import numpy as np
from sklearn import linear_model
import sklearn.metrics as sm
import matplotlib.pyplot as plt

# Вхідний файл, який містить дані
input_file = 'data_regr_4.txt'

# Завантаження даних
data = np.loadtxt(input_file, delimiter=',')
X, y = data[:, :-1], data[:, -1]

# Розбивка даних на навчальний та тестовий набори
num_training = int(0.8 * len(X))
num_test = len(X) - num_training

# Тренувальні дані
X_train, y_train = X[:num_training], y[:num_training]
# Тестові дані
X_test, y_test = X[num_training:], y[num_training:]

# Створення об'єкта лінійного регресора
regressor = linear_model.LinearRegression()
regressor.fit(X_train, y_train)

# Прогнозування результату
y_test_pred = regressor.predict(X_test)

# Побудова графіка
plt.scatter(X_test, y_test, color='green')
plt.plot(X_test, y_test_pred, color='black', linewidth=4)
plt.xticks(())
plt.yticks(())
plt.show()

print("Продуктивність лінійної регресії:")
print("Середня абсолютна похибка =", round(sm.mean_absolute_error(y_test,
y_test_pred), 2))
print("Середня квадратична помилка =", round(sm.mean_squared_error(y_test,
y_test_pred), 2))
print("Середня абсолютна помилка =", round(sm.median_absolute_error(y_test,
y_test_pred), 2))
print("Пояснена оцінка дисперсії =", round(sm.explained_variance_score(y_test,
y_test_pred), 2))
print("R2 оцінка =", round(sm.r2_score(y_test, y_test_pred), 3))

output_model_file = 'model.pkl'

# Збереження моделі
with open(output_model_file, 'wb') as f:
    pickle.dump(regressor, f)
```

```
# Завантаження моделі
y_test_pred_new = regressor.predict(X_test)
print("\nНова середня абсолютна помилка =", round(sm.mean_absolute_error(y_test,
y_test_pred_new), 2))
```

```
Продуктивність лінійної регресії:
Середня абсолютна похибка = 2.72
Середня квадратична помилка = 13.16
Середня абсолютна помилка = 1.9
Пояснена оцінка дисперсії = -0.07
R2 оцінка = -0.068

Нова середня абсолютна помилка = 2.72
```

Рис.3 Результат виконання

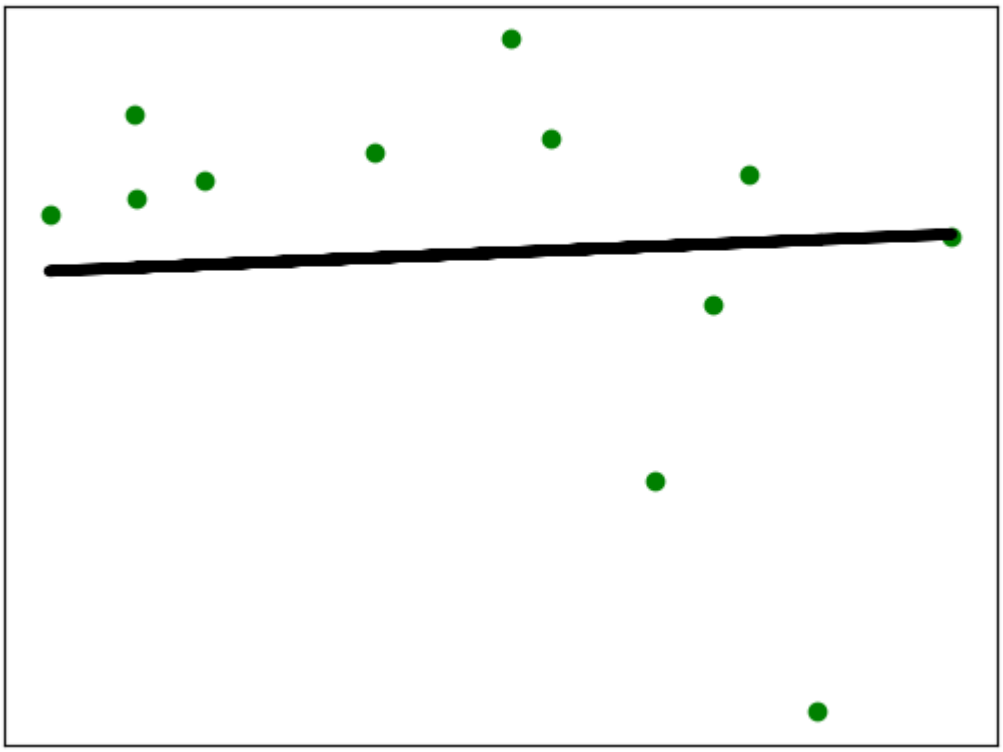

Рис. 4 Графік функції

Висновок: з графіка видно, що залишки розподілені не рівномірно щодо горизонтальної осі. Виходячи з R 2 оцінки можна зробити висновок, що продуктивність цієї моделі машинного навчання на основі регресії є поганою.

Завдання 2.3

```
import pickle
import numpy as np
from sklearn import linear_model
import sklearn.metrics as sm
import matplotlib.pyplot as plt
from sklearn.preprocessing import PolynomialFeatures

# Вхідний файл, який містить дані
input_file = 'data_multivar_regr.txt'

# Завантаження даних
data = np.loadtxt(input_file, delimiter=',')
X, y = data[:, :-1], data[:, -1]

# Розбивка даних на навчальний та тестовий набори
num_training = int(0.8 * len(X))
num_test = len(X) - num_training
# Тренувальні дані
X_train, y_train = X[:num_training], y[:num_training]
# Тестові дані
X_test, y_test = X[num_training:], y[num_training:]

# Створення об'єкта лінійного регресора
regressor = linear_model.LinearRegression()
regressor.fit(X_train, y_train)

# Прогнозування результату
y_test_pred = regressor.predict(X_test)

print("Продуктивність лінійної регресії:")
print("Середня абсолютна похибка =", round(sm.mean_absolute_error(y_test,
y_test_pred), 2))
print("Середня квадратична помилка =", round(sm.mean_squared_error(y_test,
y_test_pred), 2))
print("Середня абсолютна помилка =", round(sm.median_absolute_error(y_test,
y_test_pred), 2))
print("Пояснена оцінка дисперсії =", round(sm.explained_variance_score(y_test,
y_test_pred), 2))
print("R2 оцінка =", round(sm.r2_score(y_test, y_test_pred), 3))

output_model_file = 'model.pkl'

# Збереження моделі
with open(output_model_file, 'wb') as f:
    pickle.dump(regressor, f)

# Завантаження моделі
y_test_pred_new = regressor.predict(X_test)
print("\nНова середня абсолютна помилка =", round(sm.mean_absolute_error(y_test,
y_test_pred_new), 2))
# Поліноміальна регресія
polynomial = PolynomialFeatures(degree=10)
X_train_transformed = polynomial.fit_transform(X_train)

datapoint = [[7.75, 6.35, 5.56]]
poly_datapoint = polynomial.fit_transform(datapoint)

poly_linear_model = linear_model.LinearRegression()
poly_linear_model.fit(X_train_transformed, y_train)

print("\nLinear regression:\n", regressor.predict(datapoint))
print("\nPolynomial regression:\n", poly_linear_model.predict(poly_datapoint))
```

```
Продуктивність лінійної регресії:
Середня абсолютна похибка = 3.58
Середня квадратична помилка = 20.31
Середня абсолютна помилка = 2.99
Пояснена оцінка дисперсії = 0.86
R2 оцінка = 0.865

Нова середня абсолютна помилка = 3.58

Linear regression:
 [36.05286276]

Polynomial regression:
 [41.46678412]
```

Рис. 5 Результат виконання

Для цього коду рекомендовано використовувати поліноміальну регресію з кількох причин. По-перше, поліноміальна регресія ефективна, коли залежність між вхідними та вихідними даними є складною. Результати показали, що поліноміальна регресія (з рівнем 10) передбачає значення ознаки для точки даних datapoint краще (41.46), ніж лінійна регресія (36.05). Отже, у даному випадку поліноміальна регресія є кращим вибором для точнішого передбачення результатів.

По-друге, використання поліноміальних ознак (у цьому коді ступеню 10) робить модель більш гнучкою та допомагає краще прогнозувати дані. Важливо правильно вибрати ступінь полінома та налаштувати складність моделі, щоб уникнути перенавчання та забезпечити краще відповідання вхідним даним.

Завдання 2.4

```python
import matplotlib.pyplot as plt
import numpy as np
from sklearn import datasets, linear_model
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error

# Load the diabetes dataset
diabetes_X, diabetes_y = datasets.load_diabetes(return_X_y=True)

# Use only one feature
diabetes_X = diabetes_X[:, np.newaxis, 2]
# Split the data into training/testing sets
diabetes_X_train = diabetes_X[:-20]
diabetes_X_test = diabetes_X[-20:]
```

```
# Split the targets into training/testing sets
diabetes_y_train = diabetes_y[:-20]
diabetes_y_test = diabetes_y[-20:]

# Create linear regression object
regr = linear_model.LinearRegression()

# Train the model using the training sets
regr.fit(diabetes_X_train, diabetes_y_train)

# Make predictions using the testing set
diabetes_y_pred = regr.predict(diabetes_X_test)

# The coefficients
print("Regression coef: \n", regr.coef_)
print("Regression intercept: \n", regr.intercept_)
# Середня абсолютна похибка
print("Mean absolute error :", round(mean_absolute_error(diabetes_y_test,
diabetes_y_pred), 2))
# The mean squared error
print("Mean squared error: %.2f" % mean_squared_error(diabetes_y_test,
diabetes_y_pred))

# The coefficient of determination: 1 is perfect prediction
print("R2 score: %.2f" % r2_score(diabetes_y_test, diabetes_y_pred))

fig, ax = plt.subplots()
ax.scatter(diabetes_y_test, diabetes_y_pred, edgecolors=(0, 0, 0))
ax.plot([diabetes_y.min(), diabetes_y.max()], [diabetes_y.min(),
diabetes_y.max()], 'k--', lw=4)
ax.set_xlabel('Виміряно')
ax.set_ylabel('Передбачено')
plt.show()
```

```
Regression coef:
 [938.23786125]
Regression intercept:
 152.91886182616113
Mean absolute error : 41.23
Mean squared error: 2548.07
R2 score: 0.47
```

Рис. 6 Результат виконання

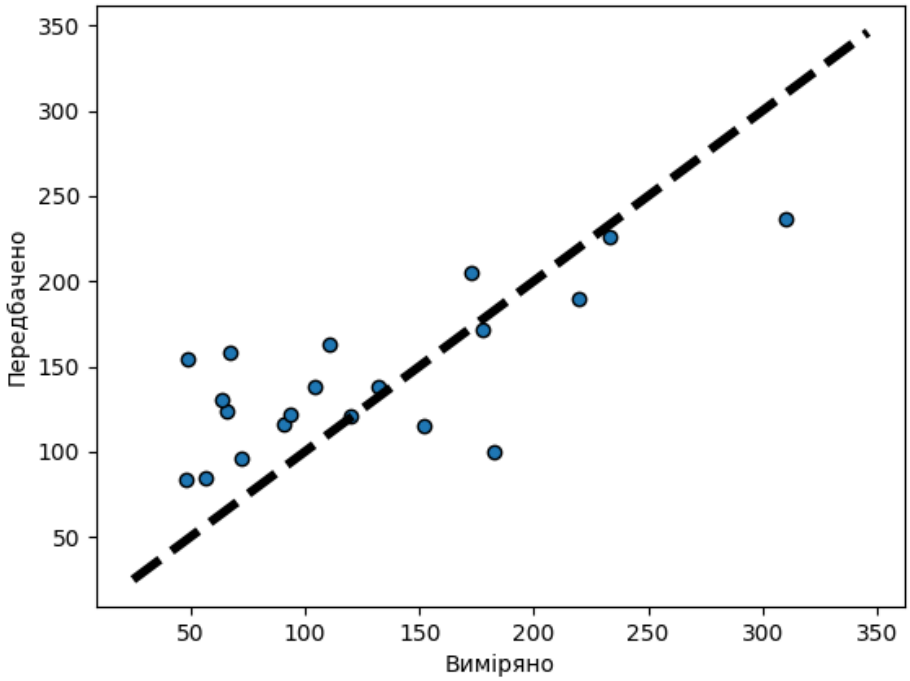

Рис. 7 Графік функції

Кожна точка на графіку представляє пару значень, де одна координата - фактичне значення, а інша - передбачене значення. Пунктирна лінія є опорною лінією, яка вказує на те, де могли б розташовуватися точки, якби передбачення моделі були абсолютно точними. Якщо точка на графіку знаходиться близько до діагональної лінії, це вказує на те, що передбачення моделі добре відповідають фактичним даним.

Завдання 2.5

Варіант 9

```
m = 100
X = np.linspace(-3, 3, m)
y = 3 + np.sin(X) + np.random.uniform(-0.5, 0.5, m)
```

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import PolynomialFeatures

m = 100
X = np.linspace(-3, 3, m)
y = 3 + np.sin(X) + np.random.uniform(-0.5, 0.5, m)

X = X.reshape(-1, 1)
Y = y.reshape(-1, 1)

lin = LinearRegression()
lin.fit(X, y)
```

```
poly = PolynomialFeatures(degree=2)
X_poly = poly.fit_transform(X)
poly.fit(X_poly, y)
lin2 = LinearRegression()
lin2.fit(X_poly, y)

Y_NEW = lin2.predict(X_poly)
r2 = r2_score(Y, Y_NEW)

print('R2: ', r2)

# Visualising the Linear Regression results
plt.scatter(X, y, color='blue')
plt.plot(X, lin.predict(X), color='red')
plt.title('Linear Regression')
plt.show()

# Visualising the Polynomial Regression results
plt.scatter(X, y, color='blue')
plt.plot(X, lin2.predict(poly.fit_transform(X)), color='red')
plt.title('Polynomial Regression')
plt.show()
```

```
R2:  0.6181376042902331
```

Рис. 8 Результат виконання

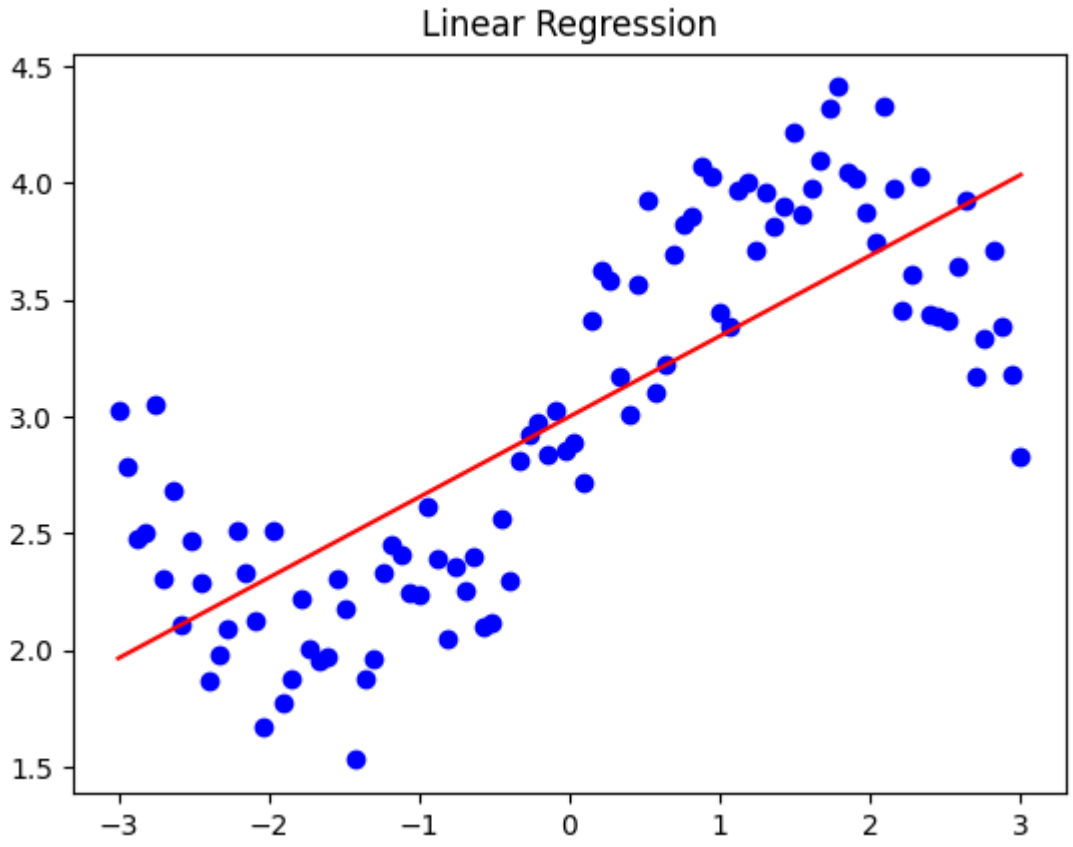

Рис. 9 Лінійна регресія

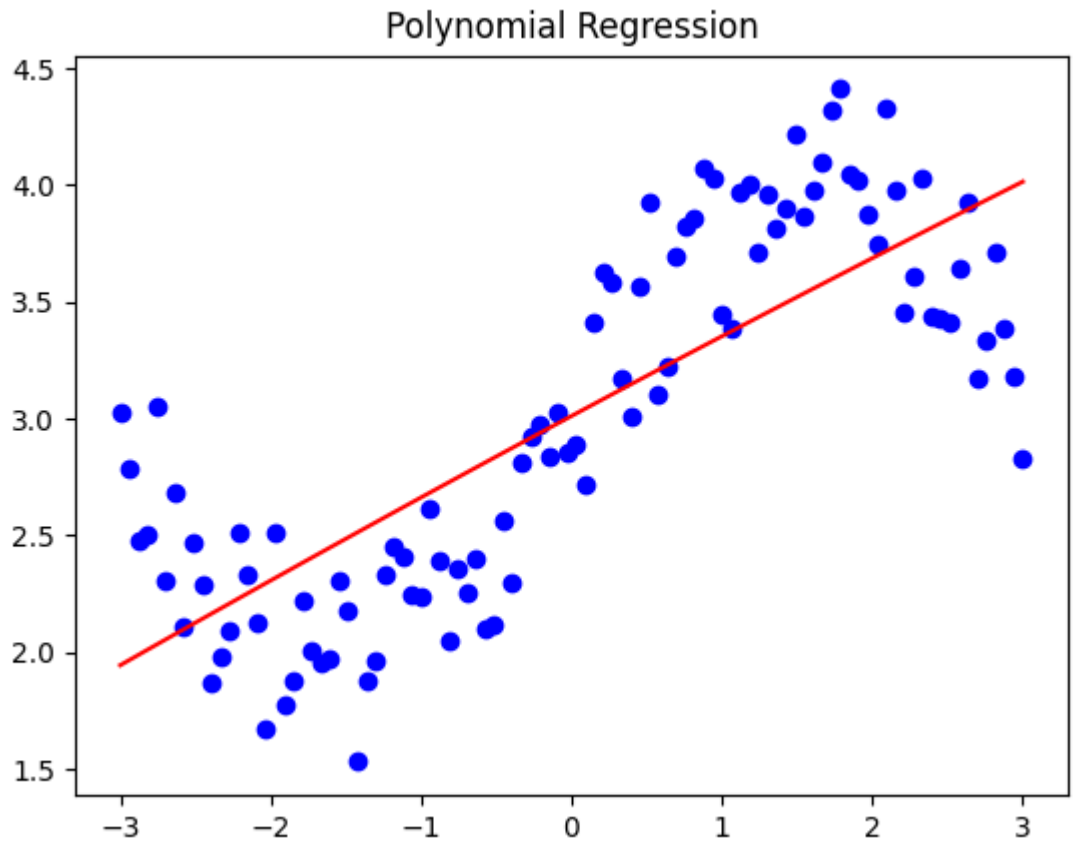

Рис. 10 Поліноміальна регресія

Завдання 2.6

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures

def plot_learning_curves(model, X, y):
    X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2)
    train_errors, val_errors = [], []
    for m in range(1, len(X_train)):
        model.fit(X_train[:m], y_train[:m])
        y_train_predict = model.predict(X_train[:m])
        y_val_predict = model.predict(X_val)
        train_errors.append(mean_squared_error(y_train_predict, y_train[:m]))
        val_errors.append(mean_squared_error(y_val_predict, y_val))
    plt.plot(np.sqrt(train_errors), "r-+", linewidth=2, label='train')
    plt.plot(np.sqrt(val_errors), "b-", linewidth=3, label='val')
    plt.show()

m = 100
X = np.linspace(-3, 3, m)
y = np.sin(X) + np.random.uniform(-0.5, 0.5, m)
X = X.reshape(-1, 1)
```

```
Y = y.reshape(-1, 1)
lin = LinearRegression()
lin.fit(X, y)

poly = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly.fit_transform(X)

poly.fit(X_poly, y)
lin2 = LinearRegression()
lin2.fit(X_poly, y)

Y_NEW = lin2.predict(X_poly)
r2 = r2_score(Y, Y_NEW)

print('R2: ', r2)

polynomial_regg = Pipeline([("poly_features", PolynomialFeatures(degree=2,
include_bias=False)),
                            ("lin_reg", LinearRegression()),])
plot_learning_curves(polynomial_regg, X, y)
```

```
R2:  0.5785854615586541
```

Рис. 11 Результат виконання

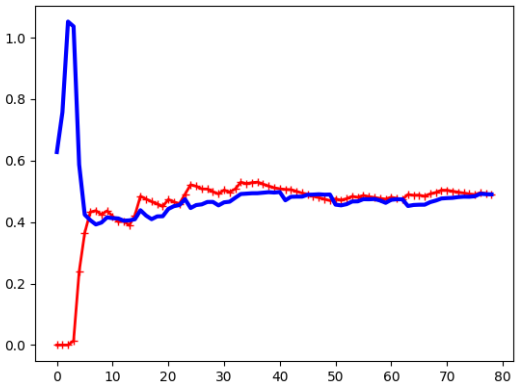

0,2

```
R2:  0.6057822557177149
```

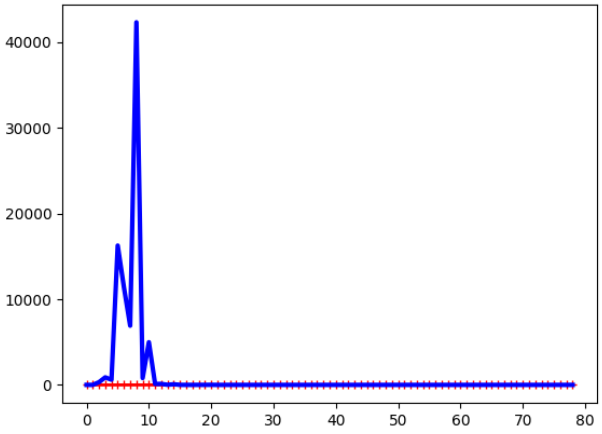

1,0

Завдання 2.7

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn import metrics

X = np.loadtxt('data_clustering.txt', delimiter=',')

num_clusters = 5

plt.figure()
plt.scatter(X[:, 0], X[:, 1], marker='o',
            facecolors='none', edgecolors='black',  s=80)

x_min, x_max = X[:, 0].min() - 1, X[:, 0].max()+1
y_min, y_max = X[:, 1].min() - 1, X[:, 1].max()+1

plt.title('Дані')
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.xticks(())
plt.yticks(())
plt.show()

kmeans = KMeans(init='k-means++', n_clusters=num_clusters, n_init=10)
kmeans.fit(X)
step_size = 0.01

x_min, x_max = X[:, 0].min() - 1, X[:, 0].max()+1
y_min, y_max = X[:, 1].min() - 1, X[:, 1].max()+1

x_vals, y_vals = np.meshgrid(
    np.arange(x_min, x_max, step_size), np.arange(y_min, y_max, step_size))
output = kmeans.predict(np.c_[x_vals.ravel(), y_vals.ravel()])

output = output.reshape(x_vals.shape)
plt.figure()
plt.clf()
plt.imshow(output, interpolation='nearest', extent=(x_vals.min(), x_vals.max(
), y_vals.min(), y_vals.max()), cmap=plt.cm.Paired, aspect='auto', origin='lower')

plt.scatter(X[:, 0], X[:, 1], marker='o',
            facecolors='none', edgecolors='black',  s=80)

cluster_center = kmeans.cluster_centers_
plt.scatter(cluster_center[:, 0], cluster_center[:, 1], marker='o',
            s=210, linewidths=4, color='black', zorder=12, facecolors='none')

x_min, x_max = X[:, 0].min() - 1, X[:, 0].max()+1
y_min, y_max = X[:, 1].min() - 1, X[:, 1].max()+1

plt.title('Границі')
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.xticks(())
plt.yticks(())
plt.show()
```

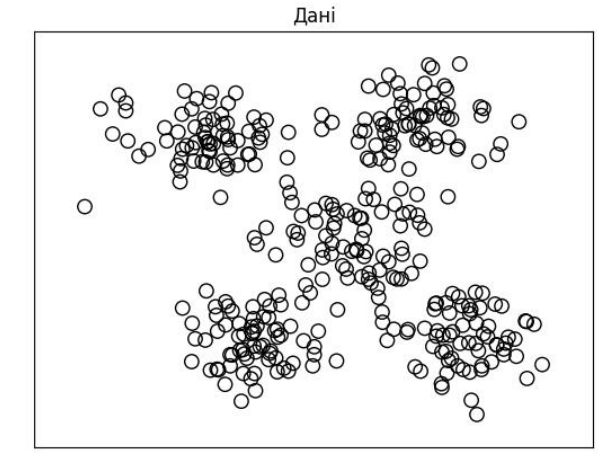

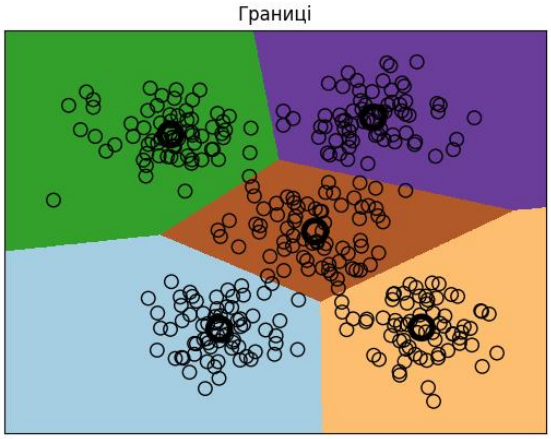

Рис. 12 Результат виконання

Завдання 2.8

```
import matplotlib.pyplot as plt
from sklearn import datasets
from sklearn.cluster import KMeans
from sklearn.metrics import pairwise_distances_argmin
import numpy as np

iris = datasets.load_iris()
X = iris.data[:, :2]
Y = iris.target

kmeans = KMeans(n_clusters=Y.max() + 1, init='k-means++', n_init=10, max_iter=300,
                tol=0.0001, verbose=0, random_state=None, copy_x=True)
kmeans.fit(X)
y_pred = kmeans.predict(X)

print("n_clusters: 3, n_init: 10, max_iter: 300, tol: 0.0001, verbose: 0,
random_state: None, copy_x: True")
print(y_pred)
```

```
plt.figure()
plt.scatter(X[:, 0], X[:, 1], c=y_pred, s=50, cmap='viridis')
centers = kmeans.cluster_centers_
plt.scatter(centers[:, 0], centers[:, 1], c='black', s=200, alpha=0.5)
plt.show()


def find_clusters(X, n_clusters, rseed=2):
    rng = np.random.RandomState(rseed)
    i = rng.permutation(X.shape[0])[:n_clusters]
    centers = X[i]

    while True:
        labels = pairwise_distances_argmin(X, centers)
        new_centers = np.array([X[labels == i].mean(0) for i in
range(n_clusters)])
        if np.all(centers == new_centers):
            break
        centers = new_centers
    return centers, labels


print("using find_clusters():")
centers, labels = find_clusters(X, 3)
print("n_clusters: 3, rseed: 2")
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap='viridis')
plt.show()

centers, labels = find_clusters(X, 3, rseed=0)
print("n_clusters: 3, rseed: 0")
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap='viridis')
plt.show()

labels = KMeans(3, random_state=0).fit_predict(X)
print("n_clusters: 3, rseed: 0")
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap='viridis')
plt.show()
```

```
C:\Users\Admin\AppData\Local\Programs\Python\Python39\python.exe "C:/Study/4 курс/Системи штучного інтелекту/lab3/task8.py"
n_clusters: 3, n_init: 10, max_iter: 300, tol: 0.0001, verbose: 0, random_state: None, copy_x: True
[2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
 2 2 2 2 2 2 2 2 2 2 2 2 0 0 0 1 0 1 0 1 0 1 1 1 1 1 1 0 1 1 1 1 1 1 1 1
 0 0 0 0 1 1 1 1 1 1 1 0 1 1 1 1 1 1 1 1 1 1 1 1 0 1 0 0 0 0 1 0 0 0 0 0
 0 0 1 1 0 0 0 0 1 0 1 0 1 0 0 1 1 0 0 0 0 0 1 1 0 0 0 1 0 0 0 1 0 0 0 1 0
 0 1]
using find_clusters():
n_clusters: 3, rseed: 2
n_clusters: 3, rseed: 0
n_clusters: 3, rseed: 0

Process finished with exit code 0
```

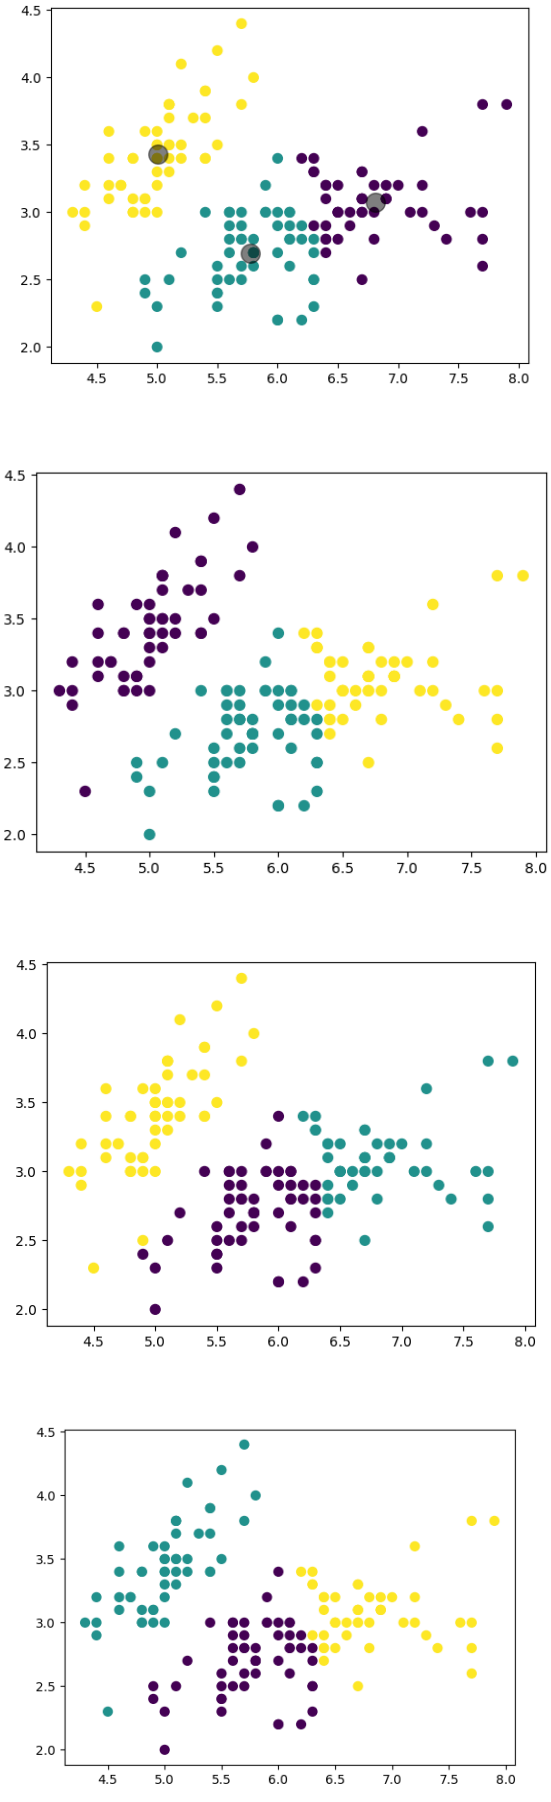

Рис. 13 Результат виконання

Код ілюструє приклади кластеризації даних за допомогою моделі KMeans з різними параметрами. Аналізуючи результати кластеризації при зміні параметрів і методів ініціалізації, можна визначити, як ці зміни впливають на результати. Це дозволяє визначити найкращий метод кластеризації для конкретної задачі та оптимізувати аналіз даних.

Завдання 2.9

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import MeanShift, estimate_bandwidth
from itertools import cycle

X = np.loadtxt('data_clustering.txt', delimiter=',')
bandwidth = estimate_bandwidth(X, quantile=0.2, n_samples=500)
ms = MeanShift(bandwidth=bandwidth, bin_seeding=True)
ms.fit(X)

cluster_centers = ms.cluster_centers_
labels = ms.labels_

print("cluster_centers:\n", cluster_centers)
print("labels:\n", labels)

plt.figure()
markers = cycle('o*sv')
colors = cycle('bgrcmyk')
for i, marker in zip(range(len(cluster_centers)), markers):
    plt.scatter(X[labels == i, 0], X[labels == i, 1], marker=marker,
color=next(colors), s=50, label='cluster ' + str(i))
    cluster_center = cluster_centers[i]
    plt.plot(cluster_center[0], cluster_center[1], marker='o',
markerfacecolor='k', markeredgecolor='k', markersize=15)
plt.title(f'Estimated number of clusters: {len(cluster_centers)}')
plt.show()
```

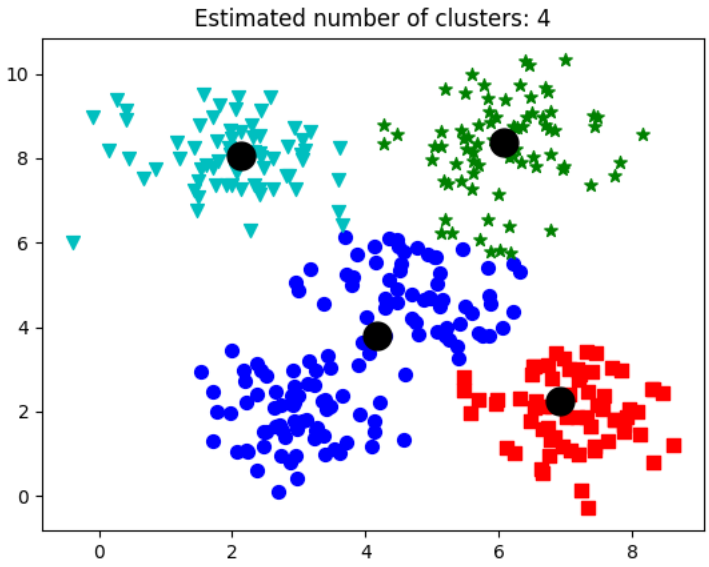

Рис. 14 Результат виконання

Наданий код ілюструє використання алгоритму MeanShift для кластеризації. У виводі вказані центри кластерів та їх кількість. Цей алгоритм дозволяє автоматично визначати кількість кластерів, що є корисним у випадках, коли заздалегідь невідомо, скільки кластерів слід шукати.

Висновки: використовуючи спеціалізовані бібліотеки та мову програмування Python дослідив методи регресії даних у машинному навчанні.

GitHub: https://github.com/unravee1/AI_labs